Hochschule Karlsruhe
University of
Applied Sciences

HKA

Hochschule Karlsruhe

– Fakultät für Maschinenbau und Mechatronik–

Berechnung von Merkmalspunkten aus Segmentierungsmasken für Visual Servoing

Projektdokumentation zum

F&E-Projekt

vorgelegt am 25. Februar 2025 von

Analena Krieger, B. Eng (100551)

Julia Kramme, B. Eng (100381)

Paul Glaser, B. Eng (100215)

Tim Schäfer, B. Eng (71606)

Erstprüfer : Prof. Dr.-Ing. Christian Friedrich
Zweitprüfer : Dominik Werman, M. Sc

Inhaltsverzeichnis

1 Einführung **3**
1.1 Zielstellung 3
1.2 Aufbau der Arbeit 3

2 Stand der Technik **4**
2.1 Klassische Verfahren der Feature-Extraktion 4
2.2 Moderne Verfahren der Feature-Extraktion 6
2.3 Segmentierungsbasierte Merkmalsextraktion 8

3 Shape Deformation based Online Augmentation ?? **10**
3.1 Aufbau ?? 10

4 Kopplung SDbOA und xFeat **11**
4.1 Kopplung der Modelle 11

5 Ergebnisse **13**
5.1 Sektion 13

6 Résumé und Ausblick **15**

A Anhang **16**

Literatur **17**

Abbildungsverzeichnis

3.1 Ablauf SDbOA 10

Tabellenverzeichnis

Abkürzungsverzeichnis

Abstract

key words: Bla, Bla und Bla

Kurzfassung

Schlagwörter: Bla, Bla und Bla

1 Einführung

Im Rahmen des Masterstudiengangs „Robotik und Künstliche Intelligenz in der Produktion“ ist die Durchführung eines Forschungs- und Entwicklungsprojekts vorgesehen. Im Sommersemester 2025 wurde dabei das Thema „Berechnung von Merkmalspunkten aus Segmentierungsmasken für Visual Servoing“ bearbeitet. Das grundsätzliche Ziel des Projekts war es, ein Konzept zur robusten Featureextraktion aus Segmentierungsmasken zu entwickeln, das für bildbasierte Regelungsverfahren in Robotersystemen eingesetzt werden kann. Im Vordergrund stand die Verbesserung der Robustheit und Dynamik visueller Steuerungsverfahren, die bisher häufig durch begrenzte Merkmalsqualität eingeschränkt sind. Gerade in der industriellen Robotik kommt der visuellen Regelung eine immer größere Bedeutung zu. Verfahren des Visual Servoing nutzen Kamerabilder zur direkten Steuerung von Roboterbewegungen und ermöglichen damit flexible und adaptive Automatisierung. Die Qualität und Verlässlichkeit solcher Systeme hängt jedoch stark von der Güte der verwendeten Bildmerkmale ab. Klassische Feature-Detektoren wie Scale-Invariant Feature Transform (SIFT) oder Oriented FAST and Rotated BRIEF (ORB) sind zwar effizient, jedoch oft anfällig für Skalierungs-, Rotations- oder Beleuchtungsänderungen – insbesondere in komplexen oder schwach texturierten Szenen. Aktuelle Forschungsarbeiten zeigen vielversprechende Ansätze, um diese Probleme zu überwinden. So zielt Accelerated Features (XFeat) auf eine besonders effiziente und hardware-unabhängige Featureextraktion, die sowohl schnell als auch genau ist und sich damit ideal für ressourcenbeschränkte Systeme wie mobile Roboter eignet. Gleichzeitig zeigt die Arbeit, dass viele neuronale Netze eine starke Texturabhängigkeit (Texture-Bias) aufweisen, was zu fehlerhaften Objektinterpretationen führen kann. Durch gezielte Formveränderungen in der Datenaugmentation kann dieses Problem reduziert werden, indem Netzwerke stärker auf strukturelle Objektformen (Shape-Bias) trainiert werden [1]. In diesem Kontext gewinnt die Nutzung von Segmentierungsmasken als strukturelle Grundlage für die Featureberechnung zunehmend an Bedeutung. Mithilfe moderner neuronaler Netze wie Mask Region-based Convolutional Neural Networks (Mask R-CNN) lassen sich Objekte nicht nur erkennen, sondern auch präzise von ihrer Umgebung abgrenzen. Diese Masken liefern zusätzliche semantische Information, die für eine robuste und gezielte Merkmalsextraktion genutzt werden kann **he2017maskrcnn**. Die Verbindung solcher Segmentierungsansätze mit effizienten Feature-Architekturen wie XFeat sowie der Einsatz von robustheitssteigernden Trainingsmethoden bietet ein vielversprechendes Potenzial für zuverlässigere und schnellere visuelle Regelungsverfahren.

1.1 Zielstellung

1.2 Aufbau der Arbeit

2 Stand der Technik

Die Extraktion robuster und invarianter Merkmale bildet eine zentrale Grundlage für bildbasierte Regelverfahren im Visual Servoing. Klassische Methoden wie SIFT oder ORB liefern stabilisierte Featurepunkte, stoßen jedoch bei komplexen Szenen und hohen Echtzeitanforderungen an ihre Grenzen. Moderne Ansätze aus dem Deep Learning ermöglichen hingegen eine datengetriebene und segmentierungsbasierte Merkmalsextraktion, die sowohl die Lokalisierung als auch die semantische Bedeutung von Bildbereichen verbessern kann. In diesem Abschnitt wird der aktuelle Stand der Technik vorgestellt: Zunächst werden klassische und moderne Verfahren zur Feature-Extraktion verglichen. Anschließend folgt ein Überblick segmentierungsbasierter Methoden wie U-Net, DeepLabV3+ und Mask R-CNN, die sich durch ihre Leistungsfähigkeit bei der semantischen Segmentierung und potenziellen Integration in Feature-Extraktion auszeichnen [1].

2.1 Klassische Verfahren der Feature-Extraktion

Klassische Verfahren der Feature-Extraktion basieren auf fest definierten Algorithmen, die charakteristische Bildpunkte anhand geometrischer und struktureller Merkmale erkennen. Diese Techniken ermöglichen eine robuste Detektion und Beschreibung von Features, insbesondere hinsichtlich Skalierung, Rotation und Beleuchtung, und bilden die Grundlage vieler etablierter Anwendungen im Bereich der Robotik und Bildverarbeitung.

2.1.1 SIFT

Das SIFT-Verfahren, eingeführt von David Lowe im Jahr 2004, ist eines der bekanntesten klassischen Verfahren zur Merkmalsextraktion in der Computer Vision.Es wurde entwickelt, um robuste lokale Merkmale in Bildern zu identifizieren, die invariant gegenüber Skalierung, Rotation und teilweise auch Beleuchtungsänderungen sowie perspektivischen Transformationen sind. Der Algorithmus besteht aus mehreren aufeinanderfolgenden Schritten. Zunächst wird eine sogenannte Scale Space erstellt, in dem das Originalbild mehrfach mit Gauß-Filtern unterschiedlicher Standardabweichung gefiltert wird. Durch Subtraktion benachbarter gefilterter Bilder entstehen Differenzen von Gaußbildern, in denen potenzielle Keypoints als lokale Extrema (Minima oder Maxima) detektiert werden. Diese Kandidatenpunkte werden anschließend auf ihre Stabilität geprüft, indem beispielsweise Kantenpunkte verworfen werden, die zu sensitiv gegenüber Rauschen sind. Danach wird jedem Keypoint eine Orientierung zugewiesen, die auf lokalen Gradienten basiert, wodurch das Verfahren rotationsinvariant wird. Im letzten Schritt wird um jeden Keypoint ein Deskriptor generiert: Dabei handelt es sich um einen Vektor, der die lokalen Gradienteninformationen in der Umgebung

zusammenfasst und somit den Charakter des lokalen Bildausschnitts beschreibt. Der SIFT-Deskriptor ist 128-dimensional und ermöglicht eine robuste Wiedererkennung von Merkmalen auch unter veränderten Bedingungen. Aufgrund seiner Robustheit wird SIFT in vielen Anwendungen wie Objekterkennung, Bildregistrierung oder Robotik eingesetzt, obwohl es im Vergleich zu modernen, lernbasierten Methoden relativ rechenintensiv ist **lowe2004distinctive**.

2.1.2 SURF

Das Speeded-Up Robust Features-Verfahren (SURF), entwickelt von Herbert Bay et al. im Jahr 2006, ist ein beschleunigter und optimierter Nachfolger des bekannten SIFT-Verfahrens zur robusten Merkmalsextraktion in Bildern. Ziel von SURF ist es, bei vergleichbarer Robustheit eine deutlich höhere Rechengeschwindigkeit zu erreichen, sodass sich das Verfahren besser für Echtzeitanwendungen eignet. Die zentrale Idee besteht darin, die aufwendige Faltung mit Gauss-Filtern durch Integralbilder und Approximierungen mit Box-Filtern zu ersetzen, was eine erheblich schnellere Berechnung ermöglicht. SURF beginnt wie SIFT mit der Detektion interessanter Punkte, allerdings verwendet es anstelle der Differenz von Gauss-Bildern eine Hessian-Matrix-basierte Detektion. Die Determinante dieser Matrix wird effizient mithilfe von Integralbildern berechnet, wodurch verschiedene Skalenebenen deutlich schneller durchlaufen werden können. Zur Beschreibung der Merkmale generiert SURF einen Deskriptor, der auf den Verteilungen von Helligkeitsgradienten basiert – ähnlich wie bei SIFT, jedoch in kompakterer und effizienterer Form. Typischerweise ist der SURF-Deskriptor 64-dimensional (eine erweiterte Version ist 128-dimensional) und enthält Informationen über die lokale Struktur eines Bildbereichs. Ein weiterer Unterschied zu SIFT liegt in der Verwendung von Haar-Wavelet-Filtern zur Extraktion der Gradienteninformationen, die durch die Nutzung von Integralbildern ebenfalls sehr schnell berechnet werden können. Durch seine Invarianz gegenüber Rotation, Skalierung und partieller Beleuchtungsveränderung eignet sich SURF gut für Aufgaben wie Objektwiedererkennung, Bildregistrierung und Robotik. Allerdings ist SURF – im Gegensatz zu SIFT – durch Patente eingeschränkt und nicht vollständig frei verfügbar, was den Einsatz in Open-Source-Projekten erschwert **bay2006surf**.

2.1.3 ORB

Die ORB-Methode, vorgestellt von Rublee et al. im Jahr 2011, ist ein effizientes und patentfreies Verfahren zur Merkmalsextraktion, das speziell für Echtzeitanwendungen und eingebettete Systeme entwickelt wurde. ORB kombiniert zwei bekannte Verfahren – Features from Accelerated Segment Test (FAST) zur Detektion von Keypoints und Binary Robust Independent Elementary Features (BRIEF) zur Beschreibung – und erweitert diese um wichtige Eigenschaften wie Rotationsinvarianz und Robustheit gegenüber Skalierung. Ziel ist es, eine leistungsfähige Alternative zu SIFT und SURF zu bieten, die deutlich schneller arbeitet und frei verwendbar ist. Im ersten Schritt verwendet ORB den FAST-Algorithmus, um schnell Ecken im Bild zu detektieren. Diese Punkte sind jedoch nicht automatisch skalen- oder rotationsinvariant. Um dies zu kompensieren, erweitert ORB FAST um eine Harris-Korner-Messung, um stabilere Keypoints auszuwählen. Anschließend wird jedem Keypoint eine Hauptorientierung

zugewiesen, indem die Intensitätsverteilungen im lokalen Bildumfeld analysiert werden. Das ist entscheidend für die Rotationstoleranz des Verfahrens. Im zweiten Schritt greift ORB auf den BRIEF-Deskriptor zurück, der sehr kompakt und effizient ist. BRIEF funktioniert auf Basis binärer Vergleiche von Pixelintensitäten innerhalb eines Patchs. ORB erweitert BRIEF zu rotated BRIEF, indem die Sampling-Punkte entsprechend der berechneten Orientierung des Keypoints angepasst werden, was eine robuste Rotationstoleranz gewährleistet. Das Ergebnis sind binäre Deskriptoren, die sehr speicher- und rechenfreundlich sind, sich aber dennoch gut zum Matching eignen. ORB ist skalierbar, echtzeitfähig und frei von Lizenzbeschränkungen, was es besonders attraktiv für mobile Anwendungen, Augmented Reality und Robotik macht. Trotz seiner Effizienz kann ORB in Bezug auf Genauigkeit und Wiedererkennung in sehr komplexen Szenen leicht hinter modernen lernbasierten Verfahren zurückfallen **rublee2011orb**.

2.2 Moderne Verfahren der Feature-Extraktion

Moderne Verfahren der Feature-Extraktion nutzen tiefenlernbasierte Modelle, um Merkmale direkt aus Bilddaten zu lernen. Einige Ansätze bieten eine hohe Robustheit gegenüber komplexen Szenen, Beleuchtungsänderungen und Verdeckungen. Sie ermöglichen eine präzisere und anpassungsfähigere Merkmalserkennung als klassische Methoden.

2.2.1 SuperPoint

SuperPoint ist ein lernbasiertes Verfahren zur Detektion und Beschreibung von lokalen Bildmerkmalen, das 2018 von DeTone, Malisiewicz und Rabin vorgestellt wurde. Es unterscheidet sich grundlegend von klassischen Ansätzen wie SIFT oder ORB, da es ein neuronales Netzwerk verwendet, das sowohl Keypoints erkennt als auch ihre Deskriptoren berechnet – und das in einem gemeinsamen, vollkonvolutionalen Pipeline. SuperPoint wurde insbesondere für Echtzeitanwendungen in der Robotik und Augmented Reality entwickelt und zeichnet sich durch hohe Wiederholbarkeit, Robustheit und Geschwindigkeit aus. Das Verfahren basiert auf einem zweistufigen Trainingsansatz. Zunächst wird ein „MagicPoint“-Netzwerk auf synthetisch erzeugten Bildern mit künstlichen Punkten trainiert. Dieses Netzwerk lernt, robuste Keypoints zu erkennen, allerdings nur in stark vereinfachten Szenen. In einem zweiten Schritt wird das Netzwerk mit echten Bildern und Homographie-Anpassung selbstüberwacht weitertrainiert. Dabei werden Bildpaare durch bekannte Transformationen verknüpft, sodass das Netzwerk lernt, konsistente Keypoints und passende Deskriptoren zu erzeugen – ganz ohne manuelle Annotation. Das SuperPoint-Netzwerk erzeugt zwei Ausgaben: eine Keypoint-Heatmap und eine dichte Deskriptormatrix. Die Heatmap zeigt, wo sich im Bild relevante Punkte befinden, während die Deskriptoren die Bildumgebung dieser Punkte als Vektoren beschreiben. Dadurch eignet sich SuperPoint besonders gut für Aufgaben wie Simultaneous Localization and Mapping (SLAM), Visual Odometry oder Structure from Motion. Ein großer Vorteil von SuperPoint ist die Kombination aus hoher Genauigkeit und Echtzeitfähigkeit auf GPU-Hardware. Es ist robuster gegenüber Skalierung, Rotation und sogar moderaten Beleuchtungsänderungen. Gleichzeitig ermöglicht das gemeinsame Lernen von Detektion und Beschreibung eine bessere Abstimmung zwischen diesen beiden Komponenten im Vergleich zu modularen Verfah-

ren **detone2018superpoint**.

2.2.2 R2D2

Repeatable and Reliable Detector and Descriptor (R2D2) ist ein lernbasiertes Verfahren zur lokalen Merkmalsextraktion, das 2019 von Revaud et al. eingeführt wurde. Ziel dieses Ansatzes ist es, Bildpunkte zu identifizieren, die sowohl wiederholbar (also unter verschiedenen Ansichten des gleichen Objekts stabil) als auch diskriminativ (gut unterscheidbar von anderen Punkten) sind. Im Gegensatz zu klassischen Methoden wie SIFT oder ORB, die fest programmierte Schritte für Keypoint-Detektion und Deskriptor-Bildung verwenden, setzt R2D2 auf ein neuronales Netz, das diese Eigenschaften direkt lernt. Das Kernprinzip von R2D2 besteht darin, ein vollkonvolutionales Netzwerk zu trainieren, das drei Karten ausgibt: eine Deskriptorkarte, eine Wiederholbarkeitskarte und eine Zuverlässigkeitskarte. Die Deskriptorkarte enthält Vektoren, die lokale Bildregionen beschreiben. Die Wiederholbarkeitskarte zeigt, wie stabil ein Punkt bei Transformationen (z.B. Rotation, Skalierung) ist, während die Zuverlässigkeitskarte angibt, wie gut sich ein Punkt zum Matching eignet. Die Kombination dieser drei Informationen erlaubt es, besonders robuste und eindeutig zuzuordnende Punkte auszuwählen. Im Training nutzt R2D2 Bildpaare mit bekannten geometrischen Transformationen (z.B. Homographien), um die gewünschten Eigenschaften der Keypoints zu erzwingen. Die Verlustfunktion belohnt Punkte, die unter diesen Transformationen wieder auftauchen (hohe Wiederholbarkeit), und bestraft Punkte, deren Deskriptoren zu ähnlich oder zu unspezifisch sind (niedrige Zuverlässigkeit). Dadurch entsteht ein Verfahren, das sowohl präzise als auch effizient ist – eine wichtige Eigenschaft für visuelle SLAM-Systeme oder Structure-from-Motion. R2D2 ist insbesondere für schwierige Bildbedingungen wie starke Perspektivwechsel oder Wiederholungsmuster (z.B. Zäune, Fensterreihen) geeignet. Durch die gleichzeitige Optimierung von Detektor- und Deskriptoreigenschaften hebt sich das Verfahren von Ansätzen wie SuperPoint ab, die diese Komponenten getrennt behandeln **revaud2019r2d2**.

2.2.3 LoFTR

Local Feature TRansformer (LoFTR) ist ein modernes, lernbasiertes Verfahren zur Feature-Korrespondenzbestimmung, das 2021 von Sun et al. vorgestellt wurde. Im Gegensatz zu klassischen Methoden wie SIFT oder auch hybriden Deep-Learning-Ansätzen wie SuperPoint + SuperGlue, verzichtet LoFTR vollständig auf die explizite Detektion einzelner Keypoints. Stattdessen verfolgt es einen „detector-free“ Ansatz, bei dem dichte Korrespondenzen direkt zwischen zwei Bildern auf Pixel- oder Patch-Ebene berechnet werden. Dies ermöglicht eine deutlich robustere Zuordnung – insbesondere in texturarmen oder stark verzerrten Szenen, in denen klassische Verfahren oft versagen. Der Kern von LoFTR ist ein Transformer-basiertes Netzwerk, das Bildpaare gleichzeitig verarbeitet und über sogenannte coarse-to-fine Matching-Strategien hochpräzise Korrespondenzen berechnet. Zunächst werden die Bildmerkmale durch ein geteiltes CNN extrahiert, anschließend mit einem „coarse-level transformer“ global abgestimmt, um grobe Korrespondenzen zu finden. Danach verfeinert ein „fine-level transformer“ die Matches lokal, um subpixelgenaue Punktpaarungen zu erzeugen. Dabei nutzt LoFTR sowohl Selbst-Attention innerhalb eines Bildes als auch Cross-Attention zwischen den

beiden Bildern – ähnlich wie es in der Sprachverarbeitung bei Übersetzungsmodellen bekannt ist. Ein bedeutender Vorteil von LoFTR ist die Fähigkeit, auch in schwierigen Szenarien wie extremen Blickwinkeländerungen, schwacher Textur oder Wiederholungsmustern robuste Matches zu liefern. Dies macht es besonders wertvoll für Anwendungen wie Structure-from-Motion, visuelle Lokalisierung und SLAM. Trotz des rechnerischen Aufwands ermöglicht eine optimierte Implementierung sogar den Einsatz in Echtzeitumgebungen mit GPU-Beschleunigung **sun2021loftr**.

2.3 Segmentierungsbasierte Merkmalsextraktion

2.3.1 Mask R-CNN

Mask R-CNN ist ein leistungsstarkes neuronales Netzwerk zur Instanzsegmentierung, das 2017 von Kaiming He et al. vorgestellt wurde. Es erkennt nicht nur Objekte in Bildern und lokalisiert sie mit Bounding Boxes, sondern erzeugt zusätzlich für jedes Objekt eine binäre Maske, die dessen exakten Umriss pixelgenau abbildet. Die Architektur besteht aus mehreren Modulen: Ein Convolutional Neural Network (CNN) extrahiert Bildmerkmale, ein Region Proposal Network (RPN) schlägt relevante Regionen vor, und mittels Region of Interest (RoI) Align werden diese Merkmale präzise auf jede Region übertragen. Für jede erkannte Region erfolgen drei parallele Vorhersagen – Objektklasse, genaue Bounding Box und Segmentierungsmaske –, wodurch das Modell End-to-End trainierbar und für anspruchsvolle Anwendungen wie Medizinbildverarbeitung, Robotik oder autonomes Fahren besonders geeignet ist. Die Entwicklung von Mask R-CNN basiert auf zwei wichtigen Vorläufermodellen, Fast R-CNN und Faster R-CNN, die schrittweise die Grundlage für seine heutige Architektur gelegt haben. Fast R-CNN wurde 2015 von Ross Girshick entwickelt und war eine effiziente Weiterentwicklung des ursprünglichen R-CNN. Es verarbeitet das gesamte Bild zunächst durch ein gemeinsames CNN und wendet anschließend RoI Pooling auf vorgeschlagene Regionen an, um Feature-Vektoren zu extrahieren. Diese Regionen stammen jedoch aus einem externen, nicht lernbaren Verfahren wie Selective Search, was die Geschwindigkeit begrenzt. Das Modell klassifiziert jede Region und optimiert gleichzeitig deren Bounding Box. Faster R-CNN wurde 2016 von Shaoqing Ren et al. vorgestellt und löst das Geschwindigkeitsproblem von Fast R-CNN durch die Einführung eines lernbasierten RPN. Dieses RPN generiert Regionsvorschläge direkt aus dem Feature-Map, wodurch das gesamte Modell vollständig end-to-end trainierbar wird. Die restliche Architektur bleibt ähnlich: RoI Pooling erzeugt Merkmalsvektoren, die zur Klassifikation und Lokalisierung verwendet werden. Faster R-CNN bildet somit die direkte Grundlage für Mask R-CNN, liefert jedoch keine Segmentierungsmaske. Durch die kontinuierliche Weiterentwicklung dieser Modellreihe konnte Mask R-CNN schließlich eine leistungsfähige Lösung für die präzise Instanzsegmentierung realisieren, die klassische Objekterkennungsverfahren deutlich übertrifft **he2017maskrcnn**.

2.3.2 U-Net

U-Net ist ein vollständig konvolutionelles neuronales Netzwerk, das 2015 von Olaf Ronneberger et al. speziell für die semantische Segmentierung entwickelt wurde. Es wurde

ursprünglich für medizinische Bilddaten konzipiert, eignet sich jedoch auch hervorragend für technische Anwendungen, bei denen eine präzise Pixel-zu-Pixel-Zuordnung erforderlich ist – etwa in der industriellen Objekterkennung, Robotik oder Visual Servoing. Der Name „U-Net“ stammt von der charakteristischen U-förmigen Architektur, die aus einem symmetrischen Encoder-Decoder-Aufbau besteht. Der Encoder-Pfad extrahiert hierarchisch Bildmerkmale durch aufeinanderfolgende Convolution- und Max-Pooling-Schritte, wobei die räumliche Auflösung reduziert und gleichzeitig die semantische Tiefe der Feature-Maps erhöht wird. Der Decoder-Pfad rekonstruiert die Bildauflösung durch transponierte Faltungen („Upconvolutions“) und kombiniert diese mit den hochauflösenden Features aus dem Encoder über Skip-Verbindungen. Diese Verbindungen sorgen dafür, dass feine Details aus den frühen Layern nicht verloren gehen – ein entscheidender Vorteil gegenüber früheren Segmentierungsmodellen. Das Netzwerk liefert als Ausgabe eine Segmentierungsmaske, in der jedem Pixel eine Klasse zugewiesen wird. U-Net kann auch auf kleinen Datensätzen effektiv trainiert werden, da es durch Datenaugmentation und die symmetrische Architektur effizient lernt. In der Praxis wird U-Net häufig verwendet, um bestimmte Objektbereiche zu erkennen (z.B. Schrauben, Leitungen), die dann gezielt zur Feature-Extraktion oder Steuerung in Vision-Systemen genutzt werden können **ronneberger2015unet**.

2.3.3 DeepLabV3+

DeepLabV3+ ist ein leistungsstarkes neuronales Netzwerk zur semantischen Segmentierung, das 2018 von Liang-Chieh Chen et al. vorgestellt wurde. Es erweitert die vorherige DeepLab-Reihe und kombiniert präzise Lokalisierungsfähigkeiten mit der Fähigkeit, kontextuelle Informationen auf mehreren Skalen zu erfassen. DeepLabV3+ ist besonders gut darin, Objekte mit komplexen Formen, variablen Größen und feinen Kanten pixelgenau zu segmentieren – was es ideal für Anwendungen in der autonomen Navigation, Robotik und Industrievision macht. Das Herzstück von DeepLabV3+ ist der sogenannte Atrous Spatial Pyramid Pooling (ASPP)-Block. Dieser verwendet dilated (atrous) Convolutions, um Informationen in verschiedenen räumlichen Auflösungen zu erfassen, ohne die Auflösung der Feature-Maps zu stark zu reduzieren. Das bedeutet: Das Netzwerk kann große Objekte vollständig erfassen und gleichzeitig feine Details erhalten – ein Balanceakt, den viele klassische CNNs nicht leisten können. Im Gegensatz zu seinem Vorgänger DeepLabV3 fügt DeepLabV3+ einen Decoder-Pfad hinzu, der die Segmentierungsergebnisse räumlich verfeinert. Dieser Teil des Netzwerks verbessert die Kantenschärfe und Detailgenauigkeit der Segmentierung deutlich – ein entscheidender Vorteil in Anwendungsbereichen, wo millimetergenaue Trennung von Objekten gefragt ist. Als Backbone für die Feature-Extraktion kann DeepLabV3+ auf leistungsstarke Netzwerke wie Xception oder ResNet zurückgreifen, was die Genauigkeit weiter erhöht. Die Architektur ist vollständig konvolutional und eignet sich daher gut für Bilder beliebiger Größe. Sie ist zudem modular und flexibel, was sie zu einem beliebten Basismodell in vielen Forschungsarbeiten macht. DeepLabV3+ ist besonders nützlich, wenn man Segmentierungsmasken für nachgelagerte Aufgaben wie Merkmalsextraktion oder Objektverfolgung benötigt **chen2018deeplabv3plus**.

3 Shape Deformation based Online Augmentation ??

3.1 Aufbau ??

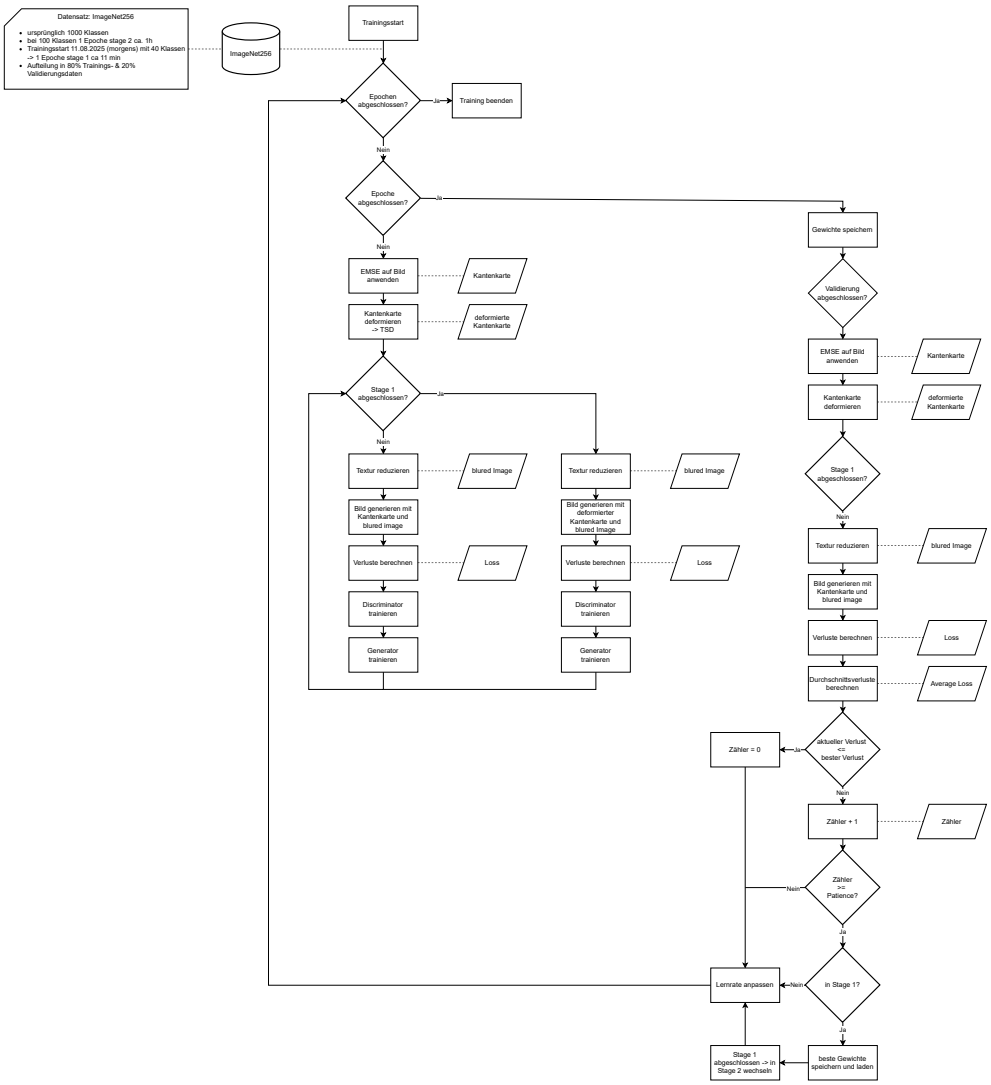


Abbildung 3.1: Ablauf SDbOA

4 Kopplung SDbOA und xFeat

4.1 Kopplung der Modelle

In diesem Bericht werden zwei Modelle zur Bildverarbeitung vorgestellt: XFeat und SDbOA. XFeat vereint eine effiziente Keypoint-Detektion, kompakte Deskriptoren und ein innovatives Match-Refinement-Modul in einem einzigen Netzwerk. Auch bei groben Merkmalen ermöglicht das Modell eine präzise Bildzuordnung und erreicht bei Aufgaben wie Kamera-Pose-Schätzung und visueller Lokalisierung vergleichbare oder sogar bessere Ergebnisse als etablierte Verfahren wie SuperPoint oder DISK – bei deutlich kürzeren Laufzeiten.

Das Modell SDbOA verfolgt einen anderen Ansatz: Es zielt darauf ab, neuronale Netze von einer textur-basierten hin zu einer strukturorientierten Merkmalsverarbeitung zu bewegen, um die Robustheit gegenüber Manipulationen zu erhöhen. Durch gezielte Formdeformationen entlang der Objektkanten und die Verwendung eines Generators mit weichen Rand- und Texturrestriktionen werden semantisch konsistente Trainingsdaten erzeugt, die die Netzwerkstabilität unter Störbedingungen verbessern.

Ein zentraler Aspekt bei der Gestaltung von Bildverarbeitungssystemen ist die Frage, ob man die einzelnen Module – etwa Generator und Feature-Extraktor – getrennt oder gemeinsam trainiert.

Beim getrennten Training wird der Generator unabhängig optimiert, beispielsweise darauf, „schöne“ deformierte Bilder zu erzeugen. Dies geschieht typischerweise mittels L1- oder adversarial Verlustfunktionen. Parallel dazu wird ein Modell wie XFeat separat auf die Extraktion von Keypoints und Deskriptoren trainiert, meist unter Verwendung realer oder augmentierter Bilddaten. Die beiden Komponenten arbeiten anschließend sequentiell: Das erzeugte Bild durchläuft den Generator und wird danach von XFeat verarbeitet. Die Lernziele sind dabei klar getrennt – der Generator fokussiert sich auf die Bildqualität, während XFeat unabhängig versucht, aus den Inputs möglichst robuste Merkmale zu extrahieren.

Im Gegensatz dazu verfolgt das gekoppelte Training eine enge Verzahnung beider Module. Hier wird der Generator direkt zusammen mit XFeat trainiert, sodass seine Bildausgaben gezielt darauf abgestimmt werden, jene Merkmale zu fördern, die XFeat für eine optimale Featureextraktion benötigt. Die Verlustfunktionen des Generators basieren in diesem Fall nicht auf klassischer Bildästhetik, sondern auf den Qualitätskriterien von XFeat, etwa in Bezug auf Keypoint-Detection oder Deskriptor-Matching. Dadurch wird der Generator explizit auf die Aufgabenstellung hin angepasst und innerhalb der Ziel-Domäne feinabgestimmt. Dies führt zu einer deutlich besseren Abstimmung beider Komponenten, was sich positiv auf die Robustheit und Gesamtperformance des Systems auswirken kann. Während die getrennte Strategie leichter zu implementieren ist und eine generische Nutzung erlaubt, bietet die gekoppelte Variante eine deutlich tiefere Integration und höhere Effektivität – insbesondere dann, wenn die Qualität der

extrahierten Features im Fokus steht.

Der Ansatz des gekoppelten Trainings findet nicht nur in theoretischen Studien Anwendung, sondern wird auch in aktuellen generativen Frameworks erfolgreich eingesetzt. Das Modell CoopInit (Zhao, Xie & Li, 2023) kombiniert kooperatives Lernen mit klassischem adversarial Training, um Generative Adversarial Networks (GANs) robuster und stabiler zu machen. Besonders bei Aufgaben wie Bildsynthese oder bei der sogenannten unpaired Image-to-Image Translation zeigt sich die Stärke dieser Methode. Dabei handelt es sich um die Übertragung von Bildern zwischen unterschiedlichen Darstellungsformen, ohne dass für jedes Bild ein passendes Gegenstück existiert. Das Modell lernt stattdessen, typische Merkmale jeder Bilddomäne zu erkennen und diese strukturell zu übersetzen. Durch das gekoppelte Training von Generator und energie-basiertem Diskriminator entstehen stabilere Lernprozesse, eine bessere Modedeckung und insgesamt eine höhere Synthesequalität. Damit bestätigt sich, dass die gemeinsame Optimierung von Netzwerksmodulen auch in modernen Deep-Learning-Anwendungen eine zentrale Rolle spielt.

4.1.1 Subsektion

Subsubsektion

5 Ergebnisse

5.1 Sektion

Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetuer id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

5.1.1 Subsektion

Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetuer id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Subsubsektion

Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetuer id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh

mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

Nulla malesuada porttitor diam. Donec felis erat, congue non, volutpat at, tincidunt tristique, libero. Vivamus viverra fermentum felis. Donec nonummy pellentesque ante. Phasellus adipiscing semper elit. Proin fermentum massa ac quam. Sed diam turpis, molestie vitae, placerat a, molestie nec, leo. Maecenas lacinia. Nam ipsum ligula, eleifend at, accumsan nec, suscipit a, ipsum. Morbi blandit ligula feugiat magna. Nunc eleifend consequat lorem. Sed lacinia nulla vitae enim. Pellentesque tincidunt purus vel magna. Integer non enim. Praesent euismod nunc eu purus. Donec bibendum quam in tellus. Nullam cursus pulvinar lectus. Donec et mi. Nam vulputate metus eu enim. Vestibulum pellentesque felis eu massa.

Quisque ullamcorper placerat ipsum. Cras nibh. Morbi vel justo vitae lacus tincidunt ultrices. Lorem ipsum dolor sit amet, consectetuer adipiscing elit. In hac habitasse platea dictumst. Integer tempus convallis augue. Etiam facilisis. Nunc elementum fermentum wisi. Aenean placerat. Ut imperdiet, enim sed gravida sollicitudin, felis odio placerat quam, ac pulvinar elit purus eget enim. Nunc vitae tortor. Proin tempus nibh sit amet nisl. Vivamus quis tortor vitae risus porta vehicula.

Fusce mauris. Vestibulum luctus nibh at lectus. Sed bibendum, nulla a faucibus semper, leo velit ultricies tellus, ac venenatis arcu wisi vel nisl. Vestibulum diam. Aliquam pellentesque, augue quis sagittis posuere, turpis lacus congue quam, in hendrerit risus eros eget felis. Maecenas eget erat in sapien mattis porttitor. Vestibulum porttitor. Nulla facilisi. Sed a turpis eu lacus commodo facilisis. Morbi fringilla, wisi in dignissim interdum, justo lectus sagittis dui, et vehicula libero dui cursus dui. Mauris tempor ligula sed lacus. Duis cursus enim ut augue. Cras ac magna. Cras nulla. Nulla egestas. Curabitur a leo. Quisque egestas wisi eget nunc. Nam feugiat lacus vel est. Curabitur consectetuer.

6 Résumé und Ausblick

Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetuer id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

Nulla malesuada porttitor diam. Donec felis erat, congue non, volutpat at, tincidunt tristique, libero. Vivamus viverra fermentum felis. Donec nonummy pellentesque ante. Phasellus adipiscing semper elit. Proin fermentum massa ac quam. Sed diam turpis, molestie vitae, placerat a, molestie nec, leo. Maecenas lacinia. Nam ipsum ligula, eleifend at, accumsan nec, suscipit a, ipsum. Morbi blandit ligula feugiat magna. Nunc eleifend consequat lorem. Sed lacinia nulla vitae enim. Pellentesque tincidunt purus vel magna. Integer non enim. Praesent euismod nunc eu purus. Donec bibendum quam in tellus. Nullam cursus pulvinar lectus. Donec et mi. Nam vulputate metus eu enim. Vestibulum pellentesque felis eu massa.

A Anhang

Literatur

[1] G. Potje, F. Cadar, A. Araujo, R. Martins und E. R. Nascimento, "XFeat: Accelerated Features for Lightweight Image Matching", *arXiv preprint arXiv:2404.19174*, 2024. Adresse: `https://arxiv.org/abs/2404.19174`.

Eidesstattliche Erklärung

Ich versichere hiermit, dass ich die vorliegende Arbeit selbständig verfasst und keine anderen als die im Literaturverzeichnis angegebenen Quellen benutzt habe.

Alle Stellen, die wörtlich oder sinngemäß aus veröffentlichten oder noch nicht veröffentlichten Quellen entnommen sind, sind als solche kenntlich gemacht.

Die Zeichnungen oder Abbildungen in dieser Arbeit sind von mir selbst erstellt worden oder mit einem entsprechenden Quellennachweis versehen.

Diese Arbeit ist in gleicher oder ähnlicher Form noch bei keiner anderen Prüfungsbehörde eingereicht worden.

Karlsruhe, 25. Februar 2025

Analena Krieger, B. Eng

Julia Kramme, B. Eng

Paul Glaser, B. Eng

Tim Schäfer, B. Eng